Random Forests vs. Bagging

Compreenda como as florestas aleatórias (Random Forests) descorrelacionam árvores de decisão para superar as limitações do bagging tradicional e aprimorar a precisão preditiva [E4].

Lucas Souza

ISLP-8.pdf. E4: p. 16, 17

O Problema da Correlação no Bagging

As árvores de decisão individuais frequentemente sofrem de alta variância [E3]. O bagging tenta resolver isso criando cópias da amostra original via bootstrap e tirando a média das previsões de várias árvores [E2, E3]. Contudo, se houver um preditor muito forte nos dados, a maioria das árvores do bagging usará esse preditor no topo da divisão [E4]. Isso faz com que as árvores fiquem muito semelhantes, gerando previsões altamente correlacionadas [E4].

Seleção Restrita de Preditores

As florestas aleatórias forçam cada divisão a considerar apenas um subconjunto aleatório m de preditores a partir do total p [E4]. A cada nova divisão, uma nova amostra aleatória de preditores é escolhida [E4].

$$m \approx \sqrt{p}$$

Em geral, o número de preditores m considerados em cada divisão é aproximadamente a raiz quadrada do total de preditores p [E4].

ISLP-8.pdf. E4: p. 16, 17

Bagging vs. Random Forests

Bagging (m = p)

Considera todos os p preditores em cada divisão [E1, E4]. Se um preditor for muito forte, todas as árvores o utilizarão, resultando em árvores altamente correlacionadas [E4].

Random Forests (m < p)

Restringe a escolha a apenas m preditores em cada divisão [E4]. Em média, (p - m) / p das divisões nem sequer considerarão o preditor forte, dando oportunidade a outros preditores [E4].

ISLP-8.pdf. E1: p. 17; E4: p. 16, 17

Por que a descorrelação melhora o desempenho?

Tirar a média de quantidades altamente correlacionadas não reduz a variância de forma tão eficiente quanto tirar a média de quantidades não correlacionadas [E4]. Ao impedir que o preditor forte domine todas as divisões, o processo de amostragem de preditores descorrelaciona as árvores [E4]. Isso torna a média final das árvores menos variável e, portanto, mais confiável, reduzindo tanto o erro de teste quanto o erro fora da bolsa (OOB error) [E1, E4].