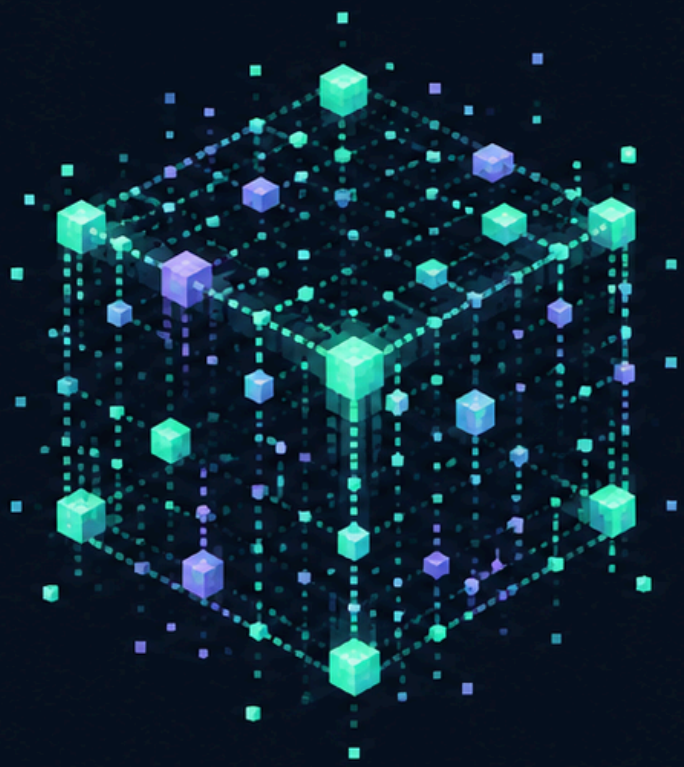
Flexibilidade e Controle em Modelos Não Lineares

Entenda as diferenças fundamentais entre a regressão polinomial e as splines de regressão, observando como o número e a alocação de nós afetam a flexibilidade do ajuste e o risco de superajuste (E1, E2).



Lucas Souza

ISLP-7.pdf. E1: p. 11, 12; E2: p. 11

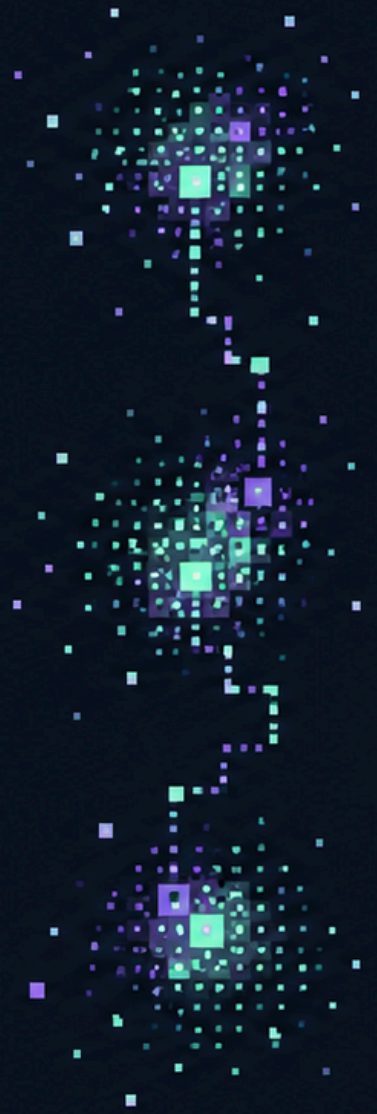
Splines de Regressão vs. Regressão Polinomial

Regressão Polinomial Global

Para aumentar a flexibilidade, exige a elevação do grau do polinômio em todo o domínio de X [E1, E4]. Isso frequentemente resulta em instabilidade e comportamentos anômalos ou oscilações indesejadas, sobretudo próximo às caudas e fronteiras dos dados [E1, E2].

Splines de Regressão

A flexibilidade é obtida aumentando o número de nós, mantendo o grau do polinômio fixo (geralmente baixo) em cada subregião [E1, E4]. Essa abordagem por partes gera estimativas mais estáveis e resultados superiores em comparação aos polinômios globais [E1].



ISLP-7.pdf. E1: p. 11, 12; E2: p. 11; E4: p. 6, 7

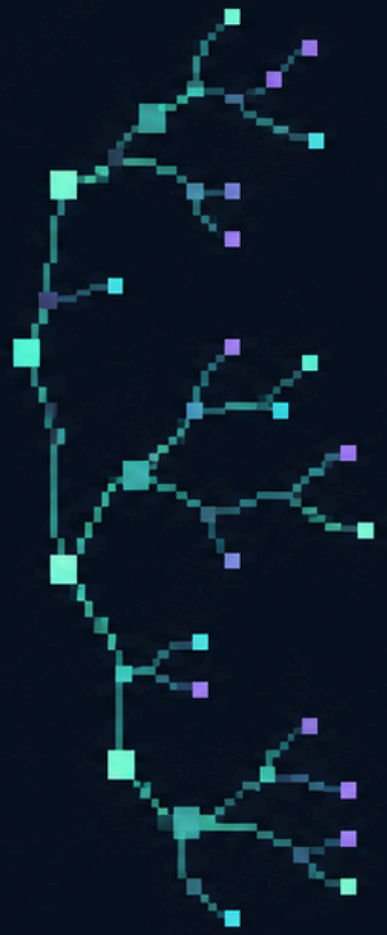
Representação por Funções de Base

As splines de regressão são ajustadas por mínimos quadrados utilizando uma combinação linear de funções de base (E1, E3). Para uma spline cúbica com K nós, o modelo adiciona termos de base e utiliza 4 + K graus de liberdade, permitindo ajustar curvas suaves com derivadas contínuas até ordem d - 1 (E3).

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \ldots + \beta_{K+3} b_{K+3}(x_i) + \varepsilon_i$$

Modelo de regressão por spline cúbica com K nós decomposto em K + 3 funções de base b_k(x) (E3).

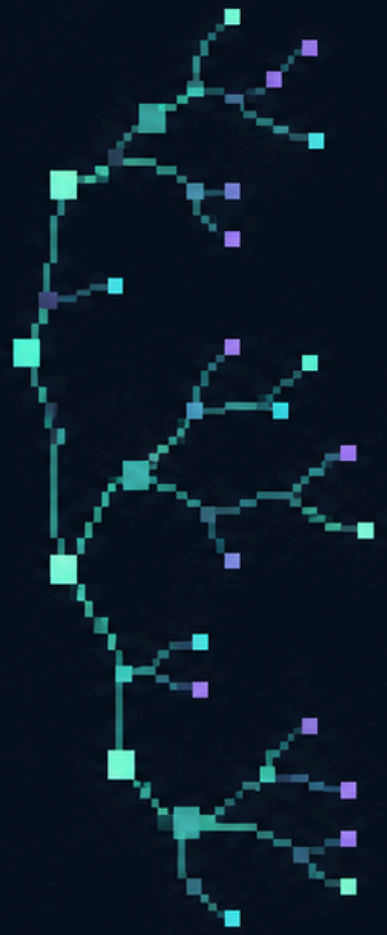
O Papel dos Nós e a Flexibilidade Local



Os nós são os pontos de divisão onde os coeficientes dos polinômios locais mudam (E4). Ao contrário dos polinômios globais, as splines possibilitam concentrar mais nós em regiões onde a função varia com rapidez para ampliar a flexibilidade local, reservando menos nós para regiões onde o comportamento é estável (E1, E8). Na prática, também se costuma posicionar os nós uniformemente em quantis dos dados a partir da escolha dos graus de liberdade (E8).

ISLP-7.pdf. E1: p. 11, 12; E4: p. 6, 7; E8: p. 10, 11

Risco de Superajuste e Seleção Objetiva



A flexibilidade excessiva sem restrições pode levar ao superajuste severo; por exemplo, uma função sem controle poderia interpolar todos os dados e anular a soma de quadrados residuais (RSS), tornando-se excessivamente flexível (E1). Para evitar curvas inadequadas, o número de nós (ou graus de liberdade) pode ser escolhido objetivamente via validação cruzada (como a de 10 dobras), calculando o RSS nos dados retidos e selecionando a quantidade K que minimiza o erro de predição fora da amostra (E2, E3).

ISLP-1.pdf, E1: p. 11, 12; E2: p. 11; E3: p. 10, 11