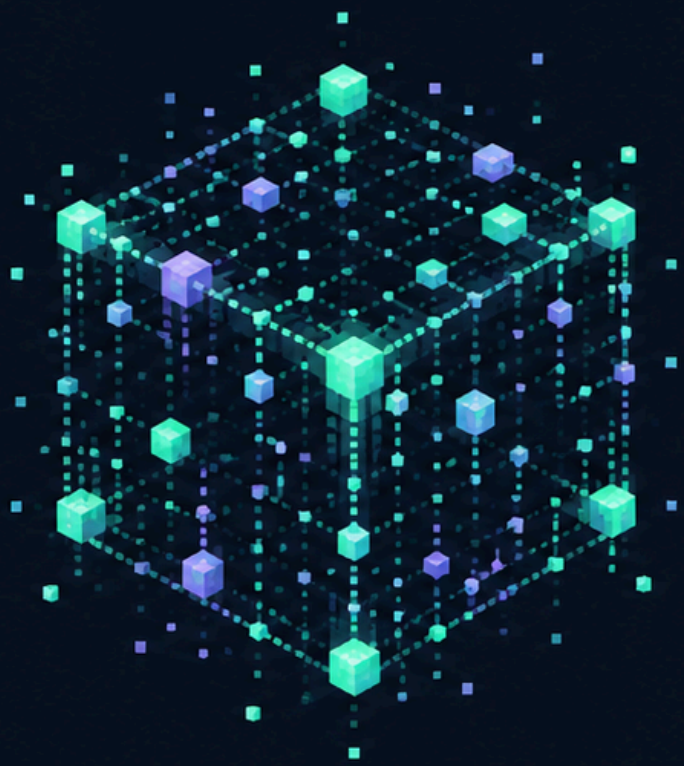
A Escolha do Número de Folds

A escolha de k na validação cruzada k-fold envolve um trade-off clássico entre viés e variância ao estimar o erro de teste (E1, E2). Além das vantagens computacionais do k-fold com k < n em relação ao LOOCV (Leave-One-Out Cross-Validation) (E1, E3), a precisão dessa estimativa é governada pelo equilíbrio entre a quantidade de dados em cada treino e a correlação entre os modelos ajustados (E1, E2).



Lucas Souza

ISLP-S.pdf. E1: p. 8, 9; E2: p. 9, 10; E3: p. 6, 7

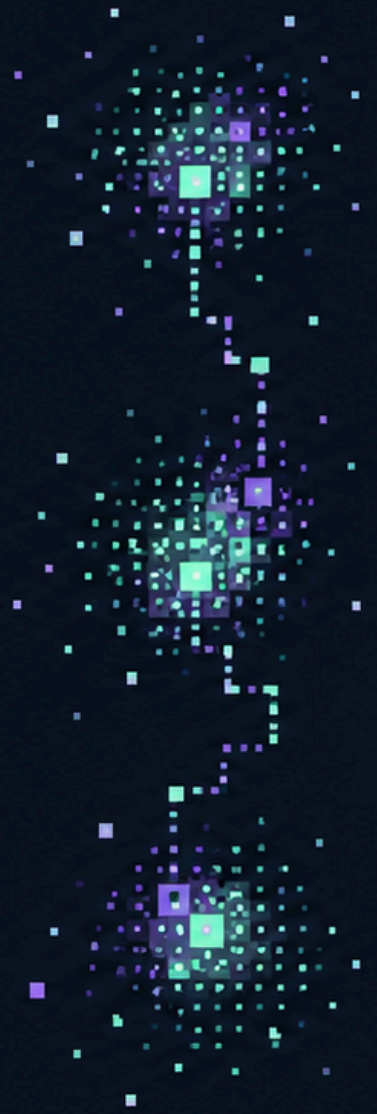
Viés vs. Variância: LOOCV e k-Fold

LOOCV (k = n)

Possui viés quase nulo, pois cada conjunto de treino utiliza n - 1 observações, praticamente todo o conjunto de dados (E1). Por outro lado, apresenta maior variância: ao calcular a média de n modelos treinados em conjuntos quase idênticos, as saídas são altamente correlacionadas positivamente, elevando a variância da média resultante (E1, E2).

k-Fold (ex.: k = 5 ou k = 10)

Apresenta um nível intermediário de viés, já que treina com aproximadamente (k - 1)n/k observações, o que é menos que o LOOCV (E1). Em contrapartida, apresenta menor variância: há menos sobreposição entre os conjuntos de treino, resultando em modelos menos correlacionados cuja média possui variância inferior (E1, E2).



ISLP-S.pdf. E1: p. 8, 9; E2: p. 9, 10

Estimativa Geral do Erro em k-Fold

A estimativa da validação cruzada k-fold é obtida pela média dos erros quadráticos médios observados em cada um dos k blocos de validação avaliados separadamente (E3).

$$\mathrm{CV}_{(k)} = \frac{1}{k}\sum_{i=1}^{k}\mathrm{MSE}_i$$

O LOOCV representa o caso particular em que k = n (E2, E3). Valores típicos como k = 5 ou k = 10 fornecem empiricamente estimativas que não sofrem de viés excessivo nem de variância muito alta (E2).

ISLP-S.pdf. E2: p. 9, 10; E3: p. 6, 7