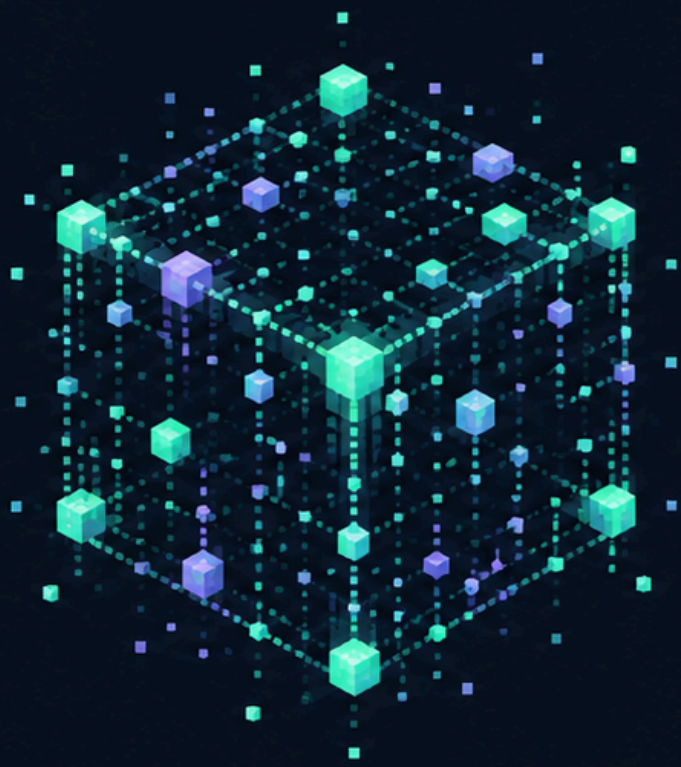
Escolha de k e o Trade-off Viés-Variância

Além de questões computacionais, a escolha do número de folds k no k-fold cross-validation envolve um trade-off direto entre viés e variância ao estimar o erro de teste, especialmente em comparação com o LOOCV (k = n) (E1, E3).



Lucas Souza

ISLP-S.pdf. E1: p. 8, 9; E3: p. 6, 7

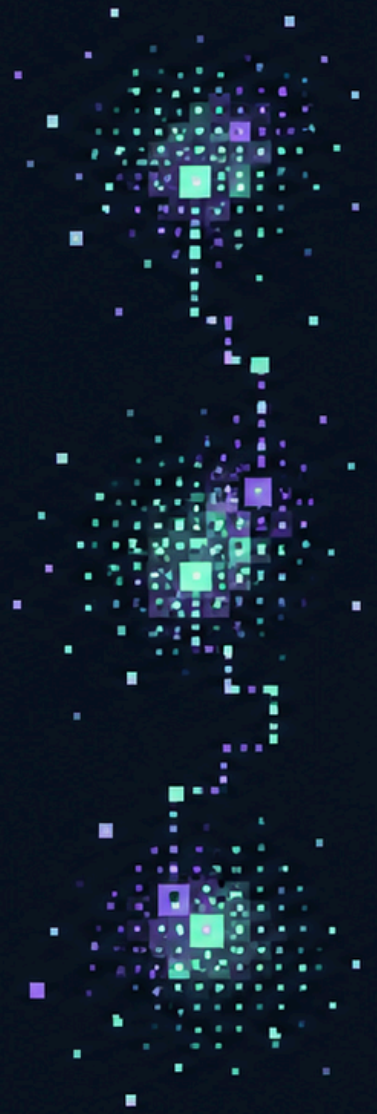
Comparação: LOOCV versus k-Fold (k < n)

LOOCV (k = n)

Viés menor: treina em n - 1 observações, gerando estimativas quase não tendenciosas do erro de teste (E1). Variância maior: calcula a média de saídas de n modelos altamente correlacionados entre si, pois seus conjuntos de treino são quase idênticos (E1).

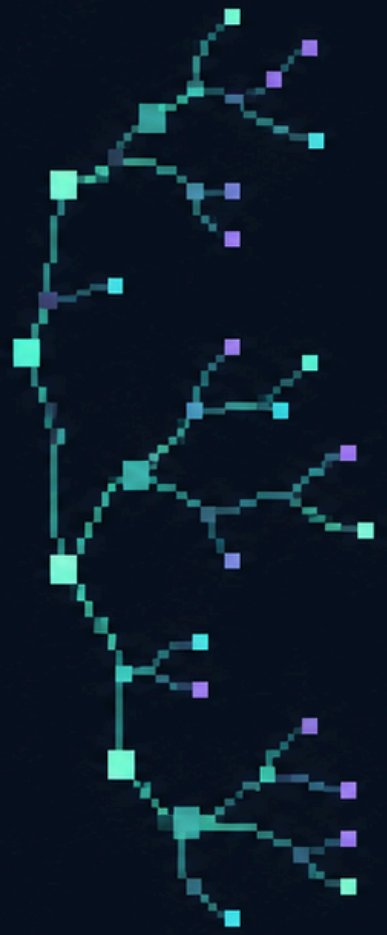
k-Fold com k < n (ex.: k = 5 ou 10)

Viés intermediário: cada conjunto de treino possui cerca de (k - 1)n/k observações, tendo mais viés que o LOOCV, mas bem menos que a abordagem de validação simples (E1). Variância menor: calcula a média de modelos com menor sobreposição de treino e menor correlação entre si (E1, E2).



ISLP-S.pdf. E1: p. 8, 9; E2: p. 9, 10

Por que k = 5 ou k = 10 é Frequentemente Escolhido?



A média de quantidades altamente correlacionadas tem maior variância do que a de grandezas menos correlacionadas, tornando a estimativa do LOOCV mais sujeita a alta variância (E1, E2). Como resultado do balanço entre viés e variância, utilizar empiricamente k = 5 ou k = 10 alcança estimativas de erro que não sofrem nem de viés excessivamente alto nem de variância muito alta, além da clara vantagem computacional sobre o LOOCV (E1, E2, E3).

ISLP-5.pdf. E1: p. 8, 9; E2: p. 9, 10; E3: p. 6, 7