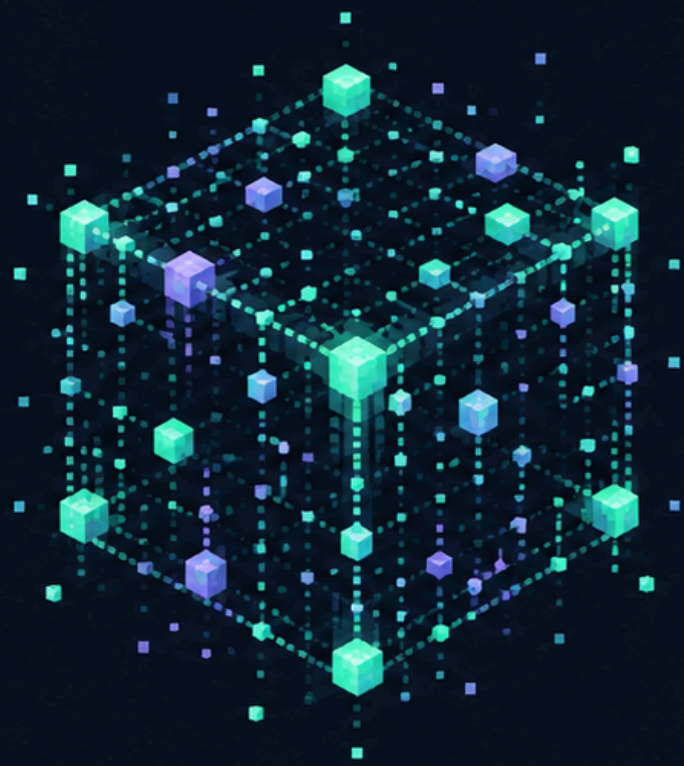
Viés e variância na validação cruzada

A escolha do número de dobras, k, envolve um compromisso entre o tamanho dos conjuntos de treino e a correlação entre os resultados das rodadas. Esses fatores ajudam a explicar o viés e a variância da estimativa do erro de teste. (E1)

O LOOCV usa quase todos os dados em cada ajuste. O k-fold com menos dobras utiliza conjuntos menores, mas também reduz a sobreposição entre eles. O ISLP discute por que valores como k = 5 ou k = 10 podem oferecer um equilíbrio útil entre esses efeitos. (E1, E2)

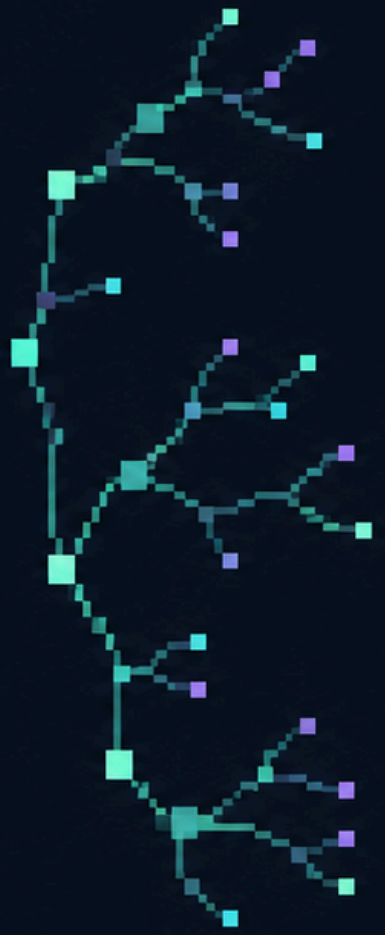
Também há uma diferença computacional: o LOOCV exige n ajustes, enquanto o k-fold exige k. (E3)



Lucas Souza

ISLP-5.pdf. E1: p. 8-9. E2: p. 9-10. E3: p. 6-7.

Viés na validação cruzada



O LOOCV corresponde ao caso em que k = n. Cada modelo utiliza n - 1 observações para treino, uma quantidade próxima do conjunto completo. Por isso, na discussão apresentada pelo ISLP, a estimativa do erro de teste é aproximadamente não viesada. (E1, E3)

No k-fold com k < n, cada conjunto de treino contém aproximadamente (k - 1)n/k observações. Como o treinamento utiliza menos dados, a estimativa tende a apresentar maior viés em relação ao LOOCV. Aumentar k aproxima o tamanho desses conjuntos daquele utilizado no LOOCV. (E1)

Essa é uma comparação do viés da estimativa do erro de teste. A escolha de k também precisa considerar sua variância e o custo computacional do procedimento. (E1, E3)

ISLP-S.pdf. E1: p. 8-9. E3: p. 6-7.

LOOCV e k-fold: o compromisso

LOOCV (k = n)

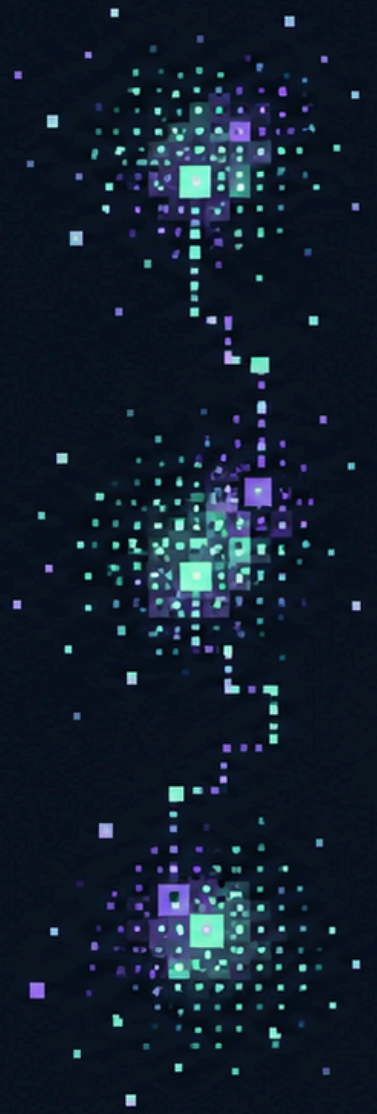
Cada rodada utiliza n - 1 observações para treino. Por trabalhar com quase todos os dados, o procedimento produz uma estimativa do erro de teste aproximadamente não viesada na discussão do livro. (E1, E3)

Os conjuntos de treino são quase idênticos. A forte correlação entre os resultados das rodadas pode elevar a variância da média usada para estimar o erro de teste. O procedimento exige n ajustes. (E1, E2, E3)

k-fold (k < n)

Os conjuntos de treino são menores, o que pode aumentar o viés em relação ao LOOCV. Em contrapartida, há menor sobreposição entre os conjuntos usados nas rodadas e menor correlação entre seus resultados. (E1)

Esse equilíbrio ajuda a explicar o uso de k = 5 ou k = 10. O procedimento requer k ajustes, reduzindo o número de treinamentos quando k < n. (E1, E2, E3)



ISLP-S.pdf. E1: p. 8-9. E2: p. 9-10. E3: p. 6-7.

Cálculo e custo do k-fold

As observações são divididas em k grupos. Cada grupo participa uma vez da validação, enquanto os demais formam o conjunto de treino. Em regressão, podemos combinar os erros quadráticos médios das rodadas para obter uma estimativa do erro de teste. (E3)

$$\mathrm{CV}_k = \frac{1}{k}\sum_{i=1}^{k}\mathrm{MSE}_i$$

Cada MSE_i representa o erro medido na dobra de validação i. A expressão calcula a média dos k erros. O k-fold exige k ajustes do modelo, enquanto o LOOCV exige n. Quando k < n, há menos ajustes a realizar. (E3)

ISLP-S.pdf. E3: p. 6-7.